



# Modelo inteligente de clasificación mediante aprendizaje supervisado para la predicción de tipologías criminales empleando datos históricos de seguridad ciudadana.

Santiago.D-Cruz<sup>1</sup> 

<sup>1</sup> Facultad de Ingeniería, Universidad Federico Villarreal, Lima, Perú.

## 2- Resumen

La inseguridad ciudadana constituye uno de los desafíos más críticos para el Estado peruano. Tradicionalmente, la asignación de recursos policiales se ha gestionado de forma reactiva, desaprovechando el potencial predictivo de los datos administrativos. El presente estudio tiene como objetivo desarrollar y evaluar algoritmos de Machine Learning para la clasificación multiclase de incidencias delictivas, utilizando exclusivamente coordenadas espaciotemporales. Siguiendo la metodología CRISP-DM, se procesó un conjunto de datos poblacional de 369,100 registros provenientes del Sistema de Denuncias Policiales (SIDPOL) del Ministerio del Interior (2018-2026). El diseño experimental comparó un modelo lineal de Regresión Logística (Baseline) frente a arquitecturas avanzadas no paramétricas (K-Nearest Neighbors y Random Forest). Los resultados demostraron que el modelo lineal base, optimizado con pesos balanceados, obtuvo el mayor rendimiento predictivo (F1-Score Macro: 0.1306), superando a las arquitecturas complejas. El análisis de interpretabilidad reveló que la codificación nominal de variables geográficas severamente desbalanceadas (como el UBIGEO) degrada la capacidad de generalización de los algoritmos basados en distancias euclidianas. Se concluye que, si bien la ubicación distrital es el predictor más fuerte del tipo de delito, el desarrollo de sistemas de policiamiento predictivo (Predictive Policing) eficaces requerirá ineludiblemente la integración de variables exógenas medioambientales y sociodemográficas.

## 3-Key words

Machine Learning; Predicción del Delito; CRISP-DM; SIDPOL; Clasificación Multiclase; Seguridad Ciudadana;

## 4-Introduction

La fenomenología criminal en áreas urbanas no obedece a una distribución espacial o temporal aleatoria. De acuerdo con las teorías de la criminología ambiental y las actividades rutinarias, el delito tiende a concentrarse en microzonas específicas impulsado por factores de oportunidad y vulnerabilidad [5]. A pesar de contar con vastos repositorios de datos históricos, como el Sistema de Denuncias Policiales (SIDPOL) del Ministerio del Interior, la analítica gubernamental en el Perú se ha limitado predominantemente a la estadística descriptiva post facto, restringiendo la capacidad operativa de la Policía Nacional para anticipar escenarios de riesgo.

El problema fundamental radica en la incapacidad técnica para procesar cientos de miles de registros históricos y extraer patrones multidimensionales ocultos que permitan clasificar qué modalidad delictiva tiene mayor probabilidad de ocurrir en una coordenada espaciotemporal determinada. En este contexto, la Inteligencia Artificial y el Machine Learning emergen como herramientas viables para transitar de un modelo de seguridad reactivo hacia uno de policiamiento predictivo (Predictive Policing).

El objetivo principal de esta investigación es estructurar un experimento controlado de minería de datos que permita entrenar, evaluar y comparar el rendimiento de distintos enfoques algorítmicos (modelos lineales vs. arquitecturas de ensamble y vecindad) en la predicción multiclase del delito. Específicamente, se busca determinar si algoritmos avanzados como K-Nearest Neighbors o Random Forest son capaces de superar una

línea base estadística tradicional utilizando únicamente variables predictoras de tiempo (año, mes) y espacio (departamento, provincia, distrito, UBIGEO).

Para garantizar el rigor científico, el proyecto adopta la metodología estándar de la industria CRISP-DM [1] (Cross-Industry Standard Process for Data Mining), respaldando cada fase con técnicas formales de ingeniería de software para asegurar la prevención de fuga de información (data leakage), la mitigación del sesgo en clases minoritarias extremas y la reproducibilidad total del artefacto de software generado. El análisis de los resultados cuantitativos permitirá aportar evidencia empírica sobre las limitaciones algorítmicas al procesar vectores geográficos nominales, sentando un precedente técnico para la modernización de los sistemas de inteligencia estratégica del Estado peruano.

## **5-Situación Problemática**

La inseguridad y el aumento constante de la delincuencia son, desde hace años, uno de los problemas más graves y difíciles que enfrenta el Perú. Afectan la economía, la gobernabilidad y la calidad de vida de la gente. No solo dañan físicamente a las víctimas o les quitan sus bienes: también desalientan la inversión privada, deterioran la salud mental de las comunidades y generan una desconfianza generalizada hacia las instituciones que deberían administrar justicia.

Cada día, comisarías y dependencias policiales de todo el país registran un volumen enorme de denuncias. Van desde hurtos al paso y faltas menores hasta delitos graves, ciberdelitos y casos de violencia contra la mujer y el grupo familiar. Toda esa información se digitaliza y se concentra en el Sistema de Denuncias Policiales (SIDPOL), administrado por el Ministerio del Interior. Con el tiempo se ha convertido en un auténtico repositorio de big data: documenta cómo se comporta la delincuencia, cómo cambia según la época del año y dónde se concentra geográficamente.

Sin embargo, aquí aparece una paradoja. A pesar de tener tantos datos históricos y verificables, las instituciones de seguridad pública siguen teniendo una capacidad analítica muy limitada. Hoy el manejo de la información es casi exclusivamente descriptivo y reactivo. Los datos del SIDPOL se usan sobre todo para armar reportes estadísticos después de los hechos, tablas de frecuencias y balances de fin de año. Sirven para responder “qué pasó”, pero no para anticipar “qué es más probable que ocurra”. Es como mirar la criminalidad solo por el espejo retrovisor, en lugar de aprovechar la información para prevenir. Faltan herramientas de minería de datos y sistemas que permitan descubrir patrones ocultos, tendencias no lineales y correlaciones complejas entre lugar y momento. Con millones de registros, el análisis manual resulta insuficiente. Sin modelos que indiquen qué tipo de delito tiene más probabilidad de ocurrir según la hora, el mes o la zona (departamento, provincia o distrito), la cadena de seguridad pública se trava.

En la práctica esto se nota. La Policía Nacional y los serenazgos de los gobiernos locales operan con presupuestos y personal limitados. Como no cuentan con modelos predictivos que focalicen el riesgo, muchas veces asignan patrullas, personal y recursos de forma intuitiva o reaccionando a emergencias que ya ocurrieron. El Estado termina siempre un paso detrás de la delincuencia. Esta brecha analítica limita seriamente la posibilidad de diseñar políticas de prevención focalizadas, proactivas y basadas en evidencia, y deja a la ciudadanía más vulnerable de lo necesario.

## **6-Problema de Investigación**

Para entender bien el fenómeno que estudiamos, delimitar el alcance de la investigación y justificar por qué hace falta una intervención tecnológica, desglosamos la situación problemática en sus partes principales, siguiendo un enfoque de causa-efecto propio de la ingeniería de sistemas.

### **6.1. Problema General**

El problema central es la limitada capacidad de las instituciones de seguridad ciudadana para analizar y predecir los delitos. No es que falte información: el problema es que no se logra procesar ni extraer conocimiento útil del enorme historial de denuncias policiales que ya existe en los sistemas del Estado. Hoy los datos se quedan en la fase de almacenamiento y de reportes descriptivos. Falta casi por completo la etapa de inteligencia predictiva, y eso impide que las autoridades tomen decisiones tácticas y estratégicas basadas en evidencia anticipada.

## 6.2. Causas Principales

Este problema general se explica por tres causas técnicas y operativas que están interconectadas:

- **A. Alto volumen y complejidad de los datos**  
El Sistema de Denuncias Policiales (SIDPOL) acumula cientos de miles de registros cada año. Es un entorno de big data con mucho volumen, actualización constante y gran variedad de variables (fechas, horas, coordenadas, tipo de delito, etc.). Esta complejidad supera ampliamente lo que pueden manejar las estadísticas tradicionales y las herramientas de oficina que suelen usar los analistas del sector público.
- **B. Falta de modelos algorítmicos en la toma de decisiones**  
Existe una clara brecha tecnológica en la administración pública respecto al uso de inteligencia artificial. Al no haber modelos de aprendizaje automático integrados en el análisis criminal, las decisiones operativas siguen dependiendo casi por completo de la intuición, la experiencia de los comisarios o el criterio del personal policial. Se deja de lado el potencial de la minería de datos.
- **C. Enfoque predominantemente reactivo**  
La doctrina actual de seguridad ciudadana está pensada para actuar cuando el delito ya ocurrió. Sin sistemas que aprovechen las variables predictivas ocultas en el historial de denuncias (estacionalidad, ubicación espacial, perfiles, etc.), resulta muy difícil avanzar hacia un modelo de policiamiento predictivo centrado en la prevención.

## 6.3. Consecuencias

No enfrentar estas causas genera varios efectos negativos que impactan tanto a la sociedad como a la eficiencia del Estado:

- **A. Distribución ineficiente de recursos**  
Al no poder anticipar qué tipo de delito es más probable en un cuadrante y en una franja horaria determinada, la asignación de personal, patrullas y logística se hace de forma uniforme o aleatoria. Eso produce sobrevigilancia en zonas de bajo riesgo en ciertos momentos y desprotección en las ventanas de tiempo más críticas.
- **B. Imposibilidad de diseñar estrategias focalizadas**  
Los delitos patrimoniales (como el hurto) y los delitos contra la persona (como la violencia familiar) tienen patrones y causas muy distintos. Sin una clasificación algorítmica previa, las autoridades terminan elaborando planes genéricos que no atacan las particularidades de cada tipo de incidencia.
- **C. Persistencia de la percepción de inseguridad**  
Al fallar la prevención, los índices de victimización se mantienen o aumentan. Esto se traduce en una sensación constante de inseguridad, deteriora la calidad de vida de la población y debilita la confianza en la capacidad de respuesta del Estado.

## 6.4. Evidencias y sustento empírico

La existencia y viabilidad de este problema se respaldan con datos públicos del Observatorio Nacional de Seguridad Ciudadana (MININTER). Este conjunto de datos registra de forma continua las denuncias policiales desde enero de 2018 hasta la actualidad. Contiene registros tabulados de delitos, faltas, fechas, ubicaciones y modalidades, lo que demuestra que el Estado ya cuenta con la materia prima necesaria. No hace falta trabajar con información ficticia ni con entornos simulados: los datos reales están disponibles y listos para un proceso de limpieza y modelado.

## 6.5. Necesidad concreta

Ante este escenario de análisis obsoleto y prevención insuficiente, surge la necesidad clara de diseñar y desarrollar un modelo computacional basado en arquitecturas de Machine Learning. Se requiere un sistema capaz de aprender de forma autónoma a partir de los datos históricos del SIDPOL para clasificar y predecir la incidencia y el tipo de delito futuro. Esta solución permitiría descubrir de manera automática patrones multidimensionales complejos y transformar los datos crudos en inteligencia accionable, con el objetivo final de optimizar las operaciones de seguridad y las estrategias de prevención del Estado.

## 7-Formulación de las preguntas de Investigación

A partir de la estructuración de la situación problemática y de las limitaciones analíticas que hoy existen en la gestión de la seguridad pública, surge la necesidad de plantear las preguntas que guiarán el desarrollo metodológico y experimental de este proyecto. Estas interrogantes buscan conectar la teoría de las ciencias de la computación y la inteligencia artificial con la solución de un problema crítico de la administración pública peruana.

### 7.1. Pregunta Principal de Investigación

¿En qué medida el diseño, desarrollo e implementación de una arquitectura predictiva basada en algoritmos de aprendizaje automático (Machine Learning) permite clasificar y predecir con alta precisión la tipología de hechos delictivos futuros, tomando como base el repositorio histórico masivo de denuncias policiales a nivel nacional, con el objetivo de transformar la gestión reactiva de la seguridad ciudadana en un modelo de prevención estratégica fundamentado en datos?

### 7.2. Preguntas Específicas de Investigación

Para responder de forma ordenada y secuencial a la pregunta principal, se formulan las siguientes preguntas específicas. Están alineadas con las fases de la metodología CRISP-DM y con las buenas prácticas de la ingeniería de software:

- **PE1 (Fase de Comprensión de los Datos)**  
¿Cuáles son las características estructurales, las distribuciones estadísticas y las variables predictoras más determinantes (espaciales, temporales y criminológicas) que se encuentran en el conjunto de datos crudos del SIDPOL y que explican matemáticamente la ocurrencia, la concentración y la tipificación de los distintos incidentes delictivos a nivel nacional?
- **PE2 (Fase de Preparación e Ingeniería de Datos)**  
¿Qué conjunto de técnicas de preprocesamiento, tratamiento de valores atípicos (outliers) e ingeniería de características (feature engineering) resulta más eficaz para transformar los registros policiales gubernamentales en una matriz de entrenamiento algorítmico óptima, garantizando una adecuada codificación de variables y evitando estrictamente la fuga de información (data leakage) entre los conjuntos de entrenamiento y prueba?
- **PE3 (Fase de Modelado y Línea Base)**  
¿En qué grado el entrenamiento de modelos de clasificación avanzados basados en inteligencia artificial logra superar los umbrales de rendimiento predictivo establecidos previamente por un modelo analítico base (baseline), justificando así el uso de arquitecturas computacionales complejas frente a métodos heurísticos o estadísticos tradicionales?
- **PE4 (Fase de Evaluación Experimental)**  
¿Qué algoritmo de aprendizaje supervisado (como K-Nearest Neighbors, Random Forest, Regresión Logística u otros) muestra la mayor robustez, capacidad de generalización y mejor desempeño cuando se somete a un diseño experimental controlado y se evalúa con métricas rigurosas (F1-Score, Precision, Recall y Matrices de Confusión), adaptadas a la naturaleza desbalanceada del fenómeno criminal?

## 8-Objetivos de la Investigación

Para responder de forma metodológica y técnica a las preguntas de investigación planteadas, y para guiar el desarrollo del proyecto bajo el marco CRISP-DM integrado con las mejores prácticas de la Ingeniería de Software, se establecen los siguientes objetivos:

### 8.1. Objetivo General (OG)

Diseñar, desarrollar y evaluar de manera rigurosa un modelo predictivo basado en algoritmos de aprendizaje automático (Machine Learning) orientado a clasificar la tipología de hechos delictivos. Como fuente empírica se utilizará el repositorio masivo de datos históricos del Sistema de Denuncias Policiales (SIDPOL) del Ministerio del Interior. El propósito central es ofrecer una herramienta tecnológica que supere las limitaciones del análisis descriptivo tradicional y apoye la toma de decisiones proactiva, la optimización de recursos y el diseño de estrategias de prevención en el ámbito de la seguridad ciudadana a nivel nacional.

## 8.2. Objetivos Específicos (OE)

Para alcanzar el objetivo general de manera sistemática, reproducible y científica, se formulan los siguientes objetivos específicos, correspondientes a cada fase del ciclo de vida del proyecto de datos:

- **OE1 (Fase de Comprensión del Negocio y de los Datos)**  
Analizar de forma exhaustiva las características, distribuciones estadísticas y factores multidimensionales asociados a las denuncias policiales mediante un Análisis Exploratorio de Datos (EDA) profundo. El objetivo es identificar la correlación entre variables predictoras (fecha, hora, departamento, provincia y distrito, entre otras) y la variable objetivo (tipo de delito), permitiendo mapear la fenomenología criminal presente en los registros del MININTER antes de aplicar cualquier procesamiento algorítmico.
- **OE2 (Fase de Preparación e Ingeniería de Datos)**  
Diseñar, codificar e implementar un pipeline automatizado de preparación e ingeniería de datos (Data Engineering). Este proceso incluirá la imputación o eliminación de valores atípicos y nulos, la codificación matemática de variables categóricas espaciales y temporales (mediante técnicas como One-Hot Encoding o Label Encoding) y el escalado de características. El propósito es construir un conjunto de datos computacionalmente idóneo y, de manera crítica, prevenir cualquier riesgo de fuga de información (data leakage) durante la partición en conjuntos de entrenamiento, validación y prueba.
- **OE3 (Fase de Modelado)**  
Diseñar, programar y entrenar de forma iterativa arquitecturas de modelado predictivo orientadas a la clasificación. Como paso metodológico obligatorio, se establecerá primero un modelo analítico base (baseline, como una Regresión Logística o un clasificador Dummy) que servirá de punto de referencia empírico. Posteriormente se implementarán y optimizarán al menos dos algoritmos avanzados de aprendizaje automático (como K-Nearest Neighbors, Random Forest o Decision Trees), configurando sus hiperparámetros para capturar la complejidad no lineal de la criminalidad.
- **OE4 (Fase de Evaluación Experimental)**  
Evaluar de forma controlada y experimental el desempeño predictivo de las arquitecturas implementadas. Dado que los conjuntos de datos de seguridad ciudadana presentan un desbalance de clases inherente (ciertos delitos menores son mucho más frecuentes que los de alto impacto), la evaluación no se limitará a la métrica engañosa de exactitud (Accuracy). En su lugar se aplicarán métricas robustas para datos asimétricos, fundamentando el análisis en Precision, Recall, F1-Score y el escrutinio detallado de las Matrices de Confusión.
- **OE5 (Fase de Comparación y Selección)**  
Contrastar y comparar cuantitativamente los resultados experimentales de los modelos avanzados frente a las métricas del modelo baseline. El propósito es demostrar de forma objetiva el valor agregado de la Inteligencia Artificial frente a métodos más simples, y seleccionar el algoritmo que ofrezca la mayor capacidad de generalización (evitando el overfitting o sobreajuste) y el mejor rendimiento para su eventual implementación.
- **OE6 (Fase de Despliegue y Reproducibilidad)**  
Integrar el modelo de aprendizaje automático seleccionado y todos los artefactos de código generados dentro de una estructura de ingeniería de software altamente reproducible. Esto implica consolidar el proyecto en un repositorio estructurado, acompañado de documentación técnica detallada, sentando las bases tecnológicas sólidas para que la solución pueda ser auditada, reproducida o escalada hacia un futuro prototipo operativo en entornos de la administración pública.

### 8.3. Matriz de Trazabilidad

Para garantizar la coherencia metodológica y estructural de la investigación, a continuación se presenta la matriz de trazabilidad. Este instrumento funciona como el hilo conductor del proyecto: alinea de forma lógica cada elemento de la situación problemática con su respectiva pregunta de investigación, los objetivos planteados, el enfoque metodológico (basado en CRISP-DM) y las evidencias objetivas que respaldan cada fase del desarrollo algorítmico.

**Tabla 1** Matriz de Trazabilidad Metodológica del Proyecto

| Problema                                                                                                                                 | Pregunta de Investigación                                                                     | Objetivo Asociado                                                                                     | Enfoque Metodológico                                                                             | Resultado esperado                                              | Evidencia                                                          |
|------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|-----------------------------------------------------------------|--------------------------------------------------------------------|
| <b>Problema Identificado:</b> Falta de capacidad para anticipar y clasificar la ocurrencia de delitos en base al historial de denuncias. | ¿En qué medida un modelo de IA permite clasificar la tipología del hecho delictivo reportado? | <b>OG:</b> Desarrollar modelo predictivo de ML para la clasificación de delitos basados en el SIDPOL. | Integración CRISP-DM y principios de Ingeniería de Software.                                     | Arquitectura de solución predictiva validada experimentalmente. | Informe de investigación final y repositorio completo.             |
| <b>Causa Fundamental:</b> Volumen masivo de datos crudos incomprensibles de forma manual.                                                | ¿Cuáles son los patrones y variables más relevantes presentes en el historial de denuncias?   | <b>OE1:</b> Realizar Análisis Exploratorio de Datos (EDA) de características temporales y espaciales. | Análisis descriptivo, visualización de distribuciones y correlaciones.                           | Identificación de patrones delictivos.                          | Gráficos (histogramas, heatmaps) e interpretación en el informe.   |
| <b>Limitación Técnica:</b> Los algoritmos requieren formatos matemáticos estructurados y libres de sesgo.                                | ¿Cómo estructurar el dataset para evitar el data leakage y optimizar el aprendizaje?          | <b>OE2:</b> Diseñar pipeline de ingeniería y preparación de datos.                                    | Limpieza (handling de nulos), estandarización, codificación categórica (One-Hot/Label Encoding). | Conjunto de datos de entrenamiento y prueba procesado.          | Data Card, scripts de preprocesamiento, dataset estructurado.      |
| <b>Necesidad Tecnológica:</b> Reemplazar el análisis reactivo por predicciones automatizadas.                                            | ¿Qué algoritmos son técnica y computacionalmente viables para este problema?                  | <b>OE3:</b> Diseñar, codificar y entrenar un modelo base y modelos avanzados.                         | Fase de Modeling (CRISP-DM): Entrenamiento supervisado de clasificadores.                        | Modelos matemáticos instanciados y entrenados.                  | Bloques de código ejecutables en el entorno de desarrollo (Colab). |
| <b>Necesidad de Decisión:</b> Garantizar que el modelo propuesto realmente aporta valor al Estado.                                       | ¿Qué algoritmo demuestra mayor eficacia predictiva frente a un modelo base?                   | <b>OE4 y OE5:</b> Evaluar controladamente y comparar el desempeño predictivo.                         | Diseño experimental, cross-validation, cálculo de métricas (Precision, Recall, F1-Score).        | Identificación técnica del algoritmo superior.                  | Tablas comparativas de métricas y Matrices de Confusión.           |

## 9-Justificación de la Investigación

La concepción, diseño y desarrollo de esta investigación va más allá de un simple ejercicio académico de programación. Se plantea como una respuesta tecnológica estructurada frente a una problemática crítica del Estado. Por ello, el proyecto se fundamenta de forma rigurosa en cuatro dimensiones clave:

### 9.1. Justificación Práctica y Operativa

Desde el punto de vista operativo y de impacto social, este proyecto ataca directamente una deficiencia estructural de la administración pública: la ineficiencia en la gestión de los recursos de seguridad ciudadana. En un contexto en el que la Policía Nacional del Perú y las municipalidades operan con severas restricciones de personal, presupuesto y logística, seguir dependiendo de un enfoque de “reacción ante la emergencia ya consumada” resulta insostenible. Contar con un modelo computacional capaz de clasificar y anticipar la tipología de la criminalidad permite a las autoridades avanzar hacia un paradigma de prevención estratégica o predictive policing (policiamiento predictivo). En la práctica, esto se traduce en beneficios concretos: optimización de las rutas de patrullaje, asignación más inteligente del presupuesto logístico en las ventanas espaciotemporales de mayor riesgo y, sobre todo, la posibilidad de reducir las tasas de victimización al anticiparse a la ocurrencia del delito, protegiendo así la integridad y el patrimonio de la ciudadanía.

### 9.2. Justificación Tecnológica

Frente al volumen masivo y la alta dimensionalidad de los registros acumulados en el Sistema de Denuncias Policiales (SIDPOL) a lo largo de los años, la elección de arquitecturas de Inteligencia Artificial y Machine Learning resulta indispensable. Los sistemas tradicionales de bases de datos relacionales (RDBMS), las consultas estructuradas (SQL) o las herramientas convencionales de inteligencia de negocios (BI) no tienen la capacidad computacional para identificar patrones estocásticos, correlaciones espaciotemporales complejas y relaciones no lineales en fracciones de segundo. Al aplicar algoritmos de aprendizaje automático, se dota a la máquina de la capacidad de inferir estas reglas matemáticas de clasificación de manera autónoma, explorando hiperespacios multidimensionales. La solución resultante no solo es altamente escalable frente al crecimiento continuo de los datos, sino que también puede mejorar y ajustar sus pesos algorítmicos de forma continua a medida que la fenomenología criminal evoluciona.

### 9.3. Justificación Científica

A nivel académico, este proyecto contribuye de manera significativa al estado del arte local en las ciencias de la computación aplicadas a la criminología. Históricamente, la mayor parte de la literatura científica y de los

modelos predictivos de seguridad ciudadana se ha entrenado y validado con conjuntos de datos de Norteamérica o Europa. Esta investigación aporta evidencia cuantitativa y novedosa sobre el comportamiento, la convergencia y la eficacia de los algoritmos de clasificación frente a un conjunto de datos genuinamente peruano, contemporáneo y con características sociodemográficas propias. De este modo, permite validar empíricamente qué arquitecturas específicas de aprendizaje supervisado capturan mejor la fenomenología delictiva nacional, estableciendo un marco de referencia (benchmark) estadístico para futuras investigaciones en el ámbito de la informática aplicada al sector público del Perú.

#### 9.4. Justificación Metodológica

Como futuro profesional de la ingeniería de sistemas e informática, el abordaje de este problema exige un nivel de rigor que va más allá de la simple codificación aislada de scripts. La investigación se justifica metodológicamente al integrar de forma estricta el estándar de la industria para ciencia de datos (metodología CRISP-DM) con las mejores prácticas de la Ingeniería de Software empírica. Esto garantiza que cada fase del proyecto —desde la comprensión del negocio hasta el modelado— esté sometida a un diseño experimental riguroso. Se asegura la correcta partición de los datos para evitar anomalías críticas como la fuga de información (data leakage), se exige la evaluación comparativa contra un modelo analítico base (baseline) y se prescinde de métricas engañosas (como el Accuracy en datos desbalanceados) en favor de indicadores robustos. En consecuencia, el resultado no es un experimento matemático efímero, sino un artefacto de software modular, documentado, libre de contaminación de datos y altamente reproducible por la comunidad académica y científica mediante repositorios de control de versiones.

### 10- Antecedentes y Estado del Arte

El desarrollo de este proyecto se fundamenta en la revisión de investigaciones previas aplicadas a la predicción delictiva:

- **Kounadi et al. (2020) [5]** estudiaron la viabilidad de los pronósticos espaciales del crimen. Utilizaron datos históricos de registros policiales bajo una metodología descriptiva y predictiva, empleando algoritmos de Machine Learning espaciotemporal. Sus métricas (Precisión y Recall) demostraron que el crimen se concentra en microzonas. Su limitación principal fue la dependencia exclusiva de datos históricos sin variables exógenas. Este antecedente se relaciona directamente con nuestro proyecto, ya que justifica nuestra selección de variables geográficas (UBIGEO, Distrito) como predictores principales.
- **Alves et al. (2018) [7]** abordaron la predicción del crimen utilizando métricas urbanas y aprendizaje estadístico. Procesaron datos estructurados con Random Forest, evaluando el modelo mediante la métrica ROC-AUC y F1-Score. Obtuvieron resultados donde los ensambles de árboles superaron a los modelos lineales. La limitación de su estudio es la alta dependencia de sistemas GIS (Sistemas de Información Geográfica) complejos. Este trabajo contrasta con nuestra investigación, permitiéndonos evaluar si, en ausencia de coordenadas GIS exactas, el Random Forest sigue siendo superior a un modelo lineal base.

### 11- Marco Conceptual

Para estandarizar la comprensión técnica del proyecto, se definen los siguientes conceptos clave sustentados en la literatura científica:

- **Machine Learning (Aprendizaje Automático):** Rama de la Inteligencia Artificial que permite a los sistemas computacionales aprender patrones y mejorar su rendimiento de forma autónoma a partir de datos empíricos, sin ser programados explícitamente mediante reglas condicionales estáticas [16].
- **Clasificación Multiclase:** Tarea de aprendizaje supervisado donde el algoritmo debe predecir a cuál categoría, dentro de un conjunto de más de dos clases discretas (ej. Hurto, Robo, Secuestro), pertenece una nueva observación [15].
- **Desbalance de Clases:** Condición estadística en un conjunto de datos donde las frecuencias de las categorías objetivo son altamente asimétricas, lo que puede inducir al modelo a sesgarse hacia la clase mayoritaria e ignorar anomalías críticas [18].
- **Data Leakage (Fuga de Información):** Error metodológico crítico donde información del conjunto de datos de validación o prueba (el "futuro") se filtra hacia el conjunto de entrenamiento, generando métricas de rendimiento artificialmente altas e inválidas [21].

## 12- Metodología de Investigación

El presente proyecto se estructura bajo un enfoque cuantitativo, ya que se fundamenta en la recolección, medición y análisis estadístico-matemático de una muestra poblacional masiva de registros numéricos y categóricos. El tipo de investigación es aplicada y tecnológica, dado que no busca únicamente la generación teórica de conocimiento, sino la resolución de un problema práctico de la administración pública. Finalmente, el diseño metodológico corresponde a la Design Science Research (DSR), puesto que el objetivo central es la concepción, desarrollo, demostración y evaluación rigurosa de un artefacto tecnológico (modelo de Inteligencia Artificial) diseñado para mejorar la eficiencia del policiamiento estratégico.

## 13- Metodología de Desarrollo de IA

Para garantizar la reproducibilidad y el rigor técnico, la construcción del modelo predictivo integra tres perspectivas metodológicas complementarias:

1. **CRISP-DM:** Se adopta como marco principal de minería de datos, estructurando el ciclo de vida en las fases de Comprensión del Problema, Comprensión de los Datos, Preparación, Modelado y Evaluación [1].
2. **Ingeniería de Software:** Se incorporan prácticas formales para el desarrollo del artefacto, incluyendo la elicitación de requisitos funcionales, el control de versiones en repositorios estructurados (Git/GitHub) y el aislamiento de entornos.
3. **Design Science Research (DSR):** Se utiliza para justificar la relevancia del problema sociopolítico, diseñar el algoritmo como una solución medible y evaluar rigurosamente su utilidad mediante diseño experimental.

## 14-Comprensión del Problema

Esta fase inicial de la metodología establece el contexto operativo, identifica a los actores involucrados y define los criterios técnicos bajo los cuales la solución de Machine Learning se considerará un éxito para la administración pública.

### 14.1. Contexto y Proceso Actual

En el ecosistema de seguridad pública del Perú, el flujo de información comienza cuando el ciudadano se acerca a las dependencias de la Policía Nacional del Perú (PNP). Las denuncias —ya sean físicas o verbales— son recepcionadas por el efectivo policial de turno, quien actúa como el primer eslabón en la digitalización de la información. Este operador registra los atributos clave del incidente (tipificación legal del delito, fecha y hora, ubicación geográfica y modalidad) en el Sistema de Denuncias Policiales (SIDPOL).

Sin embargo, el proceso operativo actual presenta una interrupción analítica importante: el ciclo de vida de los datos termina abruptamente en la fase de almacenamiento de la base de datos transaccional. La explotación de este repositorio se limita a extracciones periódicas (mensuales o anuales) orientadas exclusivamente a generar analítica descriptiva tradicional: cuadros estadísticos, conteos de frecuencias y promedios históricos, administrados por el Observatorio Nacional de Seguridad Ciudadana. La ausencia total de un componente de minería de datos o de modelado predictivo integrado en el flujo de trabajo condena a las instituciones a reaccionar únicamente ante el delito ya consumado, desperdiciando el enorme valor predictivo que se esconde en las variables del historial de incidencias.

### 14.2. Stakeholders (Interesados del Proyecto)

Los actores involucrados y beneficiarios de esta solución algorítmica se agrupan según su nivel de interacción con el modelo:

- **Interesados directos (usuarios tácticos y estratégicos)**  
Incluyen a los analistas de datos del Ministerio del Interior (MININTER), quienes integrarán estas herramientas en sus cuadros de mando, así como a los comisarios y altos mandos de las Regiones Policiales. Estos últimos utilizarán los resultados algorítmicos (predicciones de tipología delictiva según tiempo y espacio) para tomar decisiones tácticas, optimizar rutas de patrullaje y desplegar de forma inteligente a los efectivos en los cuadrantes de mayor riesgo.

- **Interesados indirectos (beneficiarios del servicio)**

Abarcan a la ciudadanía en general, que experimentará una mejora en su calidad de vida y una reducción de los índices de victimización gracias a la prevención proactiva; a las municipalidades y sus servicios de Serenazgo, que podrán articular esfuerzos disuasivos basados en datos; y al Ministerio Público, que se beneficiará de una gestión criminalística respaldada por evidencia empírica.

### 14.3. Restricciones y Riesgos Técnicos

El desarrollo del proyecto está sujeto a factores críticos que deben gestionarse con rigor durante las fases de ingeniería de datos y modelado:

- **Riesgos de calidad de datos (Data Quality)**

La naturaleza manual del ingreso de datos al SIDPOL introduce una vulnerabilidad inherente: el error humano. Existe una alta probabilidad de encontrar valores nulos (missing values), registros con ruido, inconsistencias de formato o incidentes tipificados incorrectamente por el digitador de la comisaría. Esto exigirá implementar un pipeline exhaustivo de preprocesamiento, limpieza e imputación de datos.

- **Restricciones computacionales y de dimensionalidad**

El volumen masivo de registros históricos genera un entorno de Big Data que impone una alta carga computacional. El entrenamiento de algoritmos sobre estas matrices es susceptible de generar cuellos de botella en la memoria RAM y tiempos de ejecución excesivamente largos. Esto obligará a evaluar la implementación de técnicas de reducción de dimensionalidad, selección de características (Feature Selection) y optimización eficiente de hiperparámetros.

### 14.4. Criterio de Éxito del Proyecto

Desde la perspectiva de la ciencia de datos aplicada a la seguridad, el proyecto se considerará exitoso si, y solo si, la arquitectura de aprendizaje automático desarrollada logra superar cuantitativamente el rendimiento predictivo de un modelo analítico base (baseline classifier). Dada la naturaleza inherentemente asimétrica y desbalanceada de los datos criminales (donde ciertos delitos menores superan ampliamente a los de alto impacto), este éxito no se medirá mediante la engañosa tasa de exactitud (Accuracy). En su lugar, el éxito estará ligado a la optimización de la métrica F1-Score (la media armónica entre Precision y Recall) en la clasificación de la tipología del delito. El cumplimiento de este criterio demostrará de forma matemática y empírica que la Inteligencia Artificial aporta un valor operativo tangible, superior y escalable en comparación con los métodos estadísticos descriptivos tradicionales.

## 15-Comprensión de los Datos

Siguiendo de forma estricta los lineamientos metodológicos de CRISP-DM, la fase de comprensión de los datos constituye el primer puente técnico entre la formulación del problema y el modelado computacional. Esta etapa comienza con la recolección, la carga y la familiarización empírica con el conjunto de información cruda. Para garantizar la validez, representatividad y aplicabilidad real del estudio, el dataset seleccionado fue extraído del repositorio oficial de la Plataforma Nacional de Datos Abiertos, específicamente del dominio administrado por el Observatorio Nacional de Seguridad Ciudadana del Ministerio del Interior (MININTER) del Perú. El uso de esta fuente primaria y gubernamental asegura que los algoritmos aprenderán de la fenomenología criminal auténtica del país.

### 15.1. Volumetría, Integridad y Calidad Computacional

Al ejecutar la inspección computacional inicial del archivo estructurado (.csv) mediante la librería Pandas en el entorno de Python, se determinó que el conjunto de datos posee una volumetría masiva ideal para el entrenamiento de algoritmos de Machine Learning: una matriz de 369.100 registros (filas) y 8 dimensiones (columnas). Un hallazgo técnico fundamental de esta etapa de diagnóstico es la constatación de una tasa de completitud absoluta (100 %). Es decir, la matriz cuenta con 369.100 valores no nulos en todas y cada una de sus dimensiones. Este nivel de pureza en un dataset gubernamental es estadísticamente atípico y resulta altamente beneficioso para el proyecto, ya que reduce el riesgo de introducir sesgos sintéticos, descarta la necesidad de aplicar algoritmos complejos de imputación matemática (como la sustitución por media o la imputación basada en K-Nearest Neighbors) y garantiza la integridad original de la muestra poblacional.

### 15.2. Análisis del Espacio de Características (Feature Space)

Para que los algoritmos de clasificación puedan procesar matemáticamente la información, es necesario analizar la naturaleza de las variables predictoras (características independientes). Mediante el escrutinio de

los tipos de datos computacionales (Dtype), el espacio de características se divide en dos categorías lógicas que representan las coordenadas espaciotemporales de la criminalidad:

- **Variables numéricas discretas (int64)**  
Comprenden los campos ANIO (año cronológico del registro), MES (mes del incidente, fundamental para detectar estacionalidades), UBIGEO\_HECHO (código estandarizado de ubicación geográfica) y cantidad (volumen de incidencias agregadas). Estas variables aportan la dimensionalidad métrica necesaria para el aprendizaje algorítmico.
- **Variables categóricas nominales (object)**  
Abarcan DPTO\_HECHO\_NEW (departamento político), PROV\_HECHO (provincia), DIST\_HECHO (distrito) y P\_MODALIDADES (tipología penal del delito). Dado que se encuentran en formato de cadena de texto (string), las características geográficas requerirán una etapa posterior de ingeniería de datos (codificación) para ser transformadas en tensores numéricos interpretables por el modelo.

15.3. Definición y Asimetría de la Variable Objetivo (Target)

Para los fines de este proyecto de aprendizaje supervisado y clasificación multiclase, se define formalmente como variable objetivo (Target o Label) a la columna P\_MODALIDADES. El análisis de frecuencias absolutas revela que esta variable clasifica los hechos delictivos en 7 categorías discretas. La inspección del conteo muestra la siguiente distribución: Otros (107.429 registros), Violencia contra la mujer e integrantes del grupo familiar (94.941 registros), Hurto (67.438 registros), Robo (41.751 registros), Estafa (31.004 registros), Extorsión (19.527 registros) y Secuestro (7.010 registros).

Este desglose de frecuencias pone de manifiesto un hallazgo crítico para el diseño experimental: el dataset presenta un fuerte desbalance de clases (alta asimetría). Las clases mayoritarias (Otros y Violencia) concentran la gran mayoría de las muestras, mientras que delitos de alto impacto como el Secuestro o la Extorsión representan una minoría estadística. Este comportamiento es intrínseco a la criminología real, pero algorítmicamente exige un abordaje cauteloso. El desbalance justifica metodológicamente la decisión previa de descartar el Accuracy (Exactitud) como métrica principal de evaluación, ya que un modelo podría alcanzar una alta exactitud simplemente prediciendo siempre la clase mayoritaria. Por consiguiente, obligará al equipo a utilizar técnicas de validación cruzada estratificada (Stratified Cross-Validation) y a evaluar el rendimiento final mediante el F1-Score ponderado o macro, asegurando que el modelo aprenda a detectar efectivamente las minorías criminales.

16-Ingeniería y Preparación de los datos

16.1 Data Card del Dataset

Para documentar formalmente la procedencia y la estructura técnica de los datos empleados en el entrenamiento algorítmico, se elabora la siguiente ficha técnica:

Tabla 2 Ficha Técnica (Data Card) del conjunto de datos de Denuncias Policiales

| Característica              | Descripción Técnica                                                                         |
|-----------------------------|---------------------------------------------------------------------------------------------|
| Fuente / Propietario        | Ministerio del Interior (MININTER) - Observatorio Nacional de Seguridad Ciudadana.          |
| Propósito original          | Registro histórico estadístico de denuncias en el Sistema de Denuncias Policiales (SIDPOL). |
| Periodo temporal            | Enero de 2018 a Julio de 2026.                                                              |
| Tamaño (Registros)          | 369,100 filas.                                                                              |
| Dimensionalidad (Variables) | 8 columnas (4 categóricas de tipo object y 4 numéricas de tipo int64).                      |
| Variable objetivo (Target)  | P_MODALIDADES (Clasificación del hecho delictivo).                                          |
| Calidad y Valores Faltantes | Compleitud del 100%. Cero (0) valores nulos o vacíos identificados.                         |

|                       |                                                                                                                                   |
|-----------------------|-----------------------------------------------------------------------------------------------------------------------------------|
| Sesgos potenciales    | Desbalance de clases severo en la variable objetivo (ej. Secuestros representan una minoría extrema frente a Hurtos o Violencia). |
| Formato y Procedencia | Archivo CSV (Valores separados por comas), extraído vía portal de Datos Abiertos.                                                 |
| Licencia de uso       | Open Data Commons Attribution License (Dominio público y uso libre para investigación).                                           |

16.2. Calidad de los datos

Para que el entrenamiento de los algoritmos fuera viable y riguroso, revisamos a fondo la calidad de los datos en bruto. Siguiendo los estándares habituales de minería de datos, evaluamos seis aspectos clave para confirmar que el dataset era adecuado:

1. **Compleitud**  
Al revisar la matriz de datos con la librería Pandas, comprobamos que no había ningún valor faltante en las 8 columnas. La completitud es del 100 % en los 369.100 registros iniciales. Esto es ideal, porque evita tener que rellenar datos faltantes (por ejemplo, con la media o con KNN-Imputer) y, con ello, introducir sesgos artificiales.
2. **Exactitud**  
Los datos reflejan de forma fiel la realidad delictiva del país. A diferencia de las encuestas de victimización (que se basan en lo que la gente dice haber vivido), este dataset proviene directamente de los registros oficiales del Sistema de Denuncias Policiales (SIDPOL) del Ministerio del Interior. Es decir, solo incluye hechos que ya pasaron por un filtro legal y de tipificación policial.
3. **Consistencia**  
Revisamos la coherencia lógica del dataset y confirmamos que no hay contradicciones en la jerarquía geográfica: cada distrito corresponde correctamente a su provincia y departamento. También corregimos problemas de codificación de caracteres que venían de la fuente original (por ejemplo, “ExtorsiÃ³n” se unificó en “Extorsión”). Así dejamos todas las categorías de la variable objetivo con el mismo formato.
4. **Unicidad**  
El análisis de duplicados dio un resultado óptimo: cero registros repetidos en toda la base. Esto habla bien del proceso de extracción del portal de Datos Abiertos del MININTER y garantiza que cada fila representa un incidente delictivo único en espacio y tiempo. Como no había redundancia, no hizo falta eliminar duplicados y se mantuvo el volumen original del dataset.
5. **Validez**  
Todos los datos cumplen con las reglas esperadas. Las fechas están dentro del rango documentado (años 2018 a 2026) y los códigos UBIGEO siguen el formato numérico que usa el Instituto Nacional de Estadística e Informática (INEI).
6. **Actualidad**  
El conjunto de datos está bastante actualizado: llega hasta julio de 2026. Esta cercanía temporal es importante para el modelado predictivo, porque permite que los algoritmos aprendan las dinámicas, formas de actuar y patrones delictivos actuales, y no de realidades ya desfasadas.

Para sintetizar la auditoría de los datos antes de ingresar a la fase de modelado algorítmico, se presenta la siguiente tabla de evaluación:

Tabla 3: Resumen de la Evaluación de Calidad de Datos

| Dimensión Evaluada | Criterio de Medición                    | Resultado de la Auditoría Computacional                            |
|--------------------|-----------------------------------------|--------------------------------------------------------------------|
| Compleitud         | ¿Cuántos valores faltantes existen?     | 0 valores faltantes (100% de completitud).                         |
| Exactitud          | ¿Representan correctamente el fenómeno? | Alta. Datos extraídos del SIDPOL (registros policiales oficiales). |

|                     |                                 |                                                                                      |
|---------------------|---------------------------------|--------------------------------------------------------------------------------------|
| <b>Consistencia</b> | ¿Existen contradicciones?       | <b>Superada.</b> Corrección de encoding UTF-8 en categorías delictivas.              |
| <b>Unicidad</b>     | ¿Existen duplicados?            | <b>0 duplicados.</b> Dataset sin redundancia estructural verificada matemáticamente. |
| <b>Validez</b>      | ¿Cumplen las reglas esperadas?  | <b>Aprobada.</b> Fechas lógicas (2018-2026) y UBIGEOs estructurados.                 |
| <b>Actualidad</b>   | ¿Son suficientemente recientes? | <b>Vigente.</b> Dataset actualizado hasta julio de 2026.                             |

16.3 Análisis exploratorio de datos (EDA) e interpretación






Figura 1: Distribución Histórica de Tipos de Delito

**Interpretación y Evidencia:** El análisis de la distribución de la variable objetivo revela un severo desbalance de clases. Las categorías "Otros" y "Violencia contra la mujer e integrantes" dominan abrumadoramente el volumen de registros, mientras que delitos de alto impacto como "Secuestro" y "Extorsión" representan una minoría estadística. **Evidencia que proporciona:** Este gráfico demuestra empíricamente que el uso de la métrica de Accuracy (Exactitud) será engañosa para evaluar el modelo de IA, obligando metodológicamente a utilizar métricas robustas frente al desbalance, como el F1-Score o el Recall.



**Figura 2:** Top 10 Departamentos

**Interpretación y Evidencia:** El análisis espacial demuestra una alta concentración de la criminalidad en núcleos urbanos y costeros, siendo Lima Metropolitana, Arequipa y Cusco las regiones con mayor densidad de reportes en el SIDPOL. **Evidencia que proporciona:** El gráfico evidencia que la ubicación geográfica (Departamento, Provincia, Distrito) no es una variable aleatoria, sino un predictor determinístico altamente correlacionado con la ocurrencia de los incidentes. El modelo algorítmico deberá dar un peso significativo a estas coordenadas para sus predicciones.



**Figura 3:** Volumen de Registros por Año

**Interpretación y Evidencia:** La distribución temporal muestra una tendencia incremental sostenida en las denuncias registradas desde 2018, alcanzando picos históricos durante los años 2023 y 2024. La caída observable en 2026 obedece a que es un periodo en curso (incompleto al momento de la extracción). **Evidencia que proporciona:** Se demuestra que la criminalidad posee una evolución temporal dinámica. Esta variabilidad temporal justifica la inclusión de las variables "Año" y "Mes" como características de entrada (features) vitales para el entrenamiento del modelo.

## 16.4. Preparación e Ingeniería de Datos

Para viabilizar el entrenamiento de los algoritmos de Machine Learning, el conjunto de datos fue sometido a un pipeline secuencial de preprocesamiento. Cada transformación se documentó y justificó técnicamente según las exigencias del proyecto:

- **Eliminación de duplicados y tratamiento de missing values**  
Como se demostró en la auditoría de calidad (Sección 16.2), el dataset extraído del SIDPOL presentó un 100 % de completitud y cero registros redundantes. Por lo tanto, se justificó técnicamente la omisión de purgas de duplicados y de algoritmos de imputación de nulos, preservando la integridad original del dataset.
- **Tratamiento de outliers (valores atípicos)**  
Dado que las variables de entrada son categóricas (ubicaciones geográficas) o discretas estrictas (año y mes), no aplican los conceptos estadísticos tradicionales de outliers numéricos. Cada registro es un incidente discreto válido que debe ser aprendido por el modelo, por lo que no se aplicaron recortes ni umbrales intercuartílicos.
- **Codificación**  
Los algoritmos matemáticos no pueden procesar variables espaciales en formato de texto (por ejemplo, “AMAZONAS” o “BAGUA”). Se justificó el uso de la técnica LabelEncoding de la librería Scikit-Learn [9] para mapear cada departamento, provincia y distrito a un vector numérico entero. Del mismo modo, se codificó la variable objetivo (P\_MODALIDADES).
- **Selección de variables (Feature Selection)**  
Se tomó la decisión técnica de descartar variables que introdujeran ruido algorítmico o fuga de información. Específicamente, se eliminó la variable cantidad (la cual suma los incidentes después de ocurridos) para garantizar que el modelo aprenda a clasificar basándose exclusivamente en las coordenadas espaciotemporales.
- **Estandarización y normalización**  
Tras la codificación, las variables presentaban escalas numéricas muy dispares (por ejemplo, un UBIGEO tiene 6 dígitos, mientras que el mes solo tiene 2). Para evitar que los algoritmos basados en cálculo de distancias (como KNN) sobre-ponderen las variables de mayor magnitud matemática, se aplicó una estandarización (normalización Z-score) utilizando StandardScaler[2]. Esta transformación centró los datos alrededor de la media 0 con una desviación estándar de 1, garantizando que todas las características aporten un peso equitativo al modelo.

## 16.5. Prevención de Fuga de Información (Datat Leakage)

Esta investigación garantiza estrictamente que no existió fuga de información (Data Leakage) entre los subconjuntos de datos durante el diseño experimental [21][22].

El dataset principal fue dividido mediante la técnica Train/Test Split (80 % para entrenamiento, 20 % para prueba), utilizando un muestreo estratificado (stratify=y) para mantener la proporción matemática de los delitos desbalanceados.

Para prevenir la fuga, la estandarización paramétrica (StandardScaler) se aplicó bajo una barrera computacional inquebrantable: el escalador “aprendió” los parámetros estadísticos de media y varianza exclusivamente del conjunto de Entrenamiento (Train) mediante la función fit\_transform. Luego, esos mismos parámetros históricos congelados se aplicaron al conjunto de Prueba (Test) usando únicamente transform.

Al momento de clasificar los registros del conjunto de prueba, el algoritmo de IA estaba completamente “ciego” ante el futuro. Solo tenía a su disposición los pesos matemáticos, distancias y reglas aprendidas de los registros pasados del conjunto de entrenamiento. No tuvo acceso a la distribución estadística global, ni a la variable objetivo del conjunto de prueba, ni a variables agregadas post facto como la columna cantidad (la cual fue eliminada preventivamente). Esto simula con total exactitud un entorno operativo real en una comisaría.

## 17-Diseño de la Solución

Para resolver la necesidad de predicción criminal, se diseñó una arquitectura de solución basada en un flujo de procesamiento lineal (Pipeline), la cual sigue la siguiente estructura de componentes:

Fuente de datos -> Adquisición -> Preprocesamiento -> Feature Engineering -> Modelo IA -> Predicción -> Evaluación -> Interfaz/API/Sistema -> Usuario

Para poner en marcha esta arquitectura en la práctica, se definieron los siguientes elementos técnicos que la componen:

**Componentes.** El sistema se apoya en tres motores principales: uno de ingesta de datos (Pandas) [3], encargado de leer y organizar la información; uno de preprocesamiento (Scikit-Learn), que prepara los datos para el modelo; y uno de inferencia algorítmica, basado en el clasificador KNN.

**Módulos.** El flujo se divide en tres módulos: limpieza y codificación de datos, escalamiento numérico y evaluación de métricas.

**Entradas.** El punto de partida es un archivo .csv con los registros históricos de denuncias policiales, que incluye tanto variables espaciales como temporales.

**Procesos.** Sobre esos datos se aplican, en orden, la codificación mediante LabelEncoding, la estandarización con Z-Score, una división estratificada 80/20 entre entrenamiento y prueba, y finalmente el cálculo de distancias en el hiperespacio durante el entrenamiento del modelo.

**Salidas.** Como resultado, el sistema entrega un vector de predicción discreta (valores del 0 al 6), donde cada número corresponde a una tipología específica de delito.

**Interfaces.** Todo el desarrollo se ejecuta en un entorno interactivo, ya sea Jupyter Notebook o Google Colab [4].

**Tecnologías.** El stack completo incluye Python 3, Pandas, Scikit-Learn, Matplotlib, Seaborn y Google Colab.

## 17.1. Técnicas de ingeniería de software

El desarrollo de esta solución no se limita al análisis estadístico, sino que también sigue prácticas formales de ingeniería de software:

- **Requisitos:**
  - Funcionales: el sistema debe poder cargar datos en formato CSV, codificar las variables categóricas geográficas y predecir el tipo de delito a partir de un nuevo registro.
  - No funcionales: la predicción debe realizarse en tiempo casi real (del orden de milisegundos), y la precisión obtenida debe superar la del modelo base.

**Modelado:** el flujo de datos (data pipeline) se diseñó de manera que el preprocesador alimenta directamente al modelo predictivo, evitando ciclos que puedan provocar fuga de datos. Dentro de los casos de uso se considera a un "Analista de Seguridad" como el usuario que interpreta las métricas finales.

**Gestión del código:** el control de versiones se lleva con Git, y la solución está alojada en un repositorio de GitHub organizado en tres carpetas principales: datos (data/), código fuente (src/) y experimentación (notebooks/). Además, se incluyó un README detallado para facilitar su reproducibilidad.

**Calidad:** el modelo se validó de forma exhaustiva usando métricas de clasificación sobre un conjunto de prueba aislado (testing set), verificando que las transformaciones matemáticas aplicadas funcionen correctamente.

## 18. Desarrollo de la Implementación

### 18.1. Diseño del Modelo de IA

En estricto cumplimiento del rigor analítico, se justifica técnicamente la parametrización del motor predictivo:

**Algoritmo seleccionado:** K-Nearest Neighbors (KNN) para clasificación multiclase [12].

**Alternativas consideradas:** Regresión Logística Multinomial y Random Forest.

**Variables de entrada:** Seis (6) características espaciotemporales: ANIO, MES, DPTO\_HECHO\_NEW, PROV\_HECHO, DIST\_HECHO, UBIGEO\_HECHO.

**Variable objetivo:** P\_MODALIDADES (clasificación discreta en 7 tipologías criminales).

**Hiperparámetros:** Número de vecinos  $K=1$ , ponderación uniforme (`weights='uniform'`) y métrica de distancia de Minkowski (euclidiana,  $p=2$ ).

**Función de pérdida:** al tratarse de un algoritmo de aprendizaje perezoso (lazy learning), KNN no optimiza una función de pérdida tradicional (como Log-Loss) mediante gradientes durante el entrenamiento. En su lugar, minimiza el error de clasificación de forma heurística, conservando la estructura topológica del espacio de entrenamiento.

**Estrategia de entrenamiento:** se realiza un ajuste topológico (fit) sobre el 80 % de los datos históricos, vectorizando las coordenadas espaciotemporales.

**Estrategia de validación:** División Hold-out estratificada (stratified train-test split) que preserva la distribución de las clases minoritarias en el conjunto de prueba (20 %).

**Justificación técnica:** Se seleccionó KNN (y no algoritmos lineales) porque es intrínsecamente apropiado para el fenómeno criminal. El delito tiene una altísima dependencia espacial (ley de Tobler: todo está relacionado con todo, pero las cosas cercanas están más relacionadas) [7]. Un incidente delictivo en un distrito específico está fuertemente correlacionado con su "vecindario" histórico, convirtiendo a KNN en el algoritmo matemáticamente más natural para este tipo de datos topológicos.

**Justificación del cambio a Random Forest:** Al realizar los primeros experimentos con KNN, se observó que el rendimiento quedaba por debajo del modelo base. La razón técnica es que KNN calcula distancias euclidianas. Al haber codificado los departamentos con números (LabelEncoding), el algoritmo interpreta de forma incorrecta las distancias geográficas: por ejemplo, asume que el departamento 1 está "lejos" del 15, cuando en realidad esa numeración es solo un código y no refleja proximidad real.

Para resolver este problema se incorporó un algoritmo de Random Forest [10][11]. Este modelo basado en árboles resulta más adecuado para este tipo de datos porque no calcula distancias, sino que separa los datos mediante reglas lógicas no lineales. De esta forma maneja muy bien las variables categóricas espaciales y evita el problema de dimensionalidad que presentaba KNN.

## 18.2. Modelo Base (Baseline)

Todo diseño predictivo requiere un punto de referencia estadístico. Para este proyecto, se instanció como modelo baseline una Regresión Logística Multinomial (ponderada para clases desbalanceadas) [13]. Este modelo asume relaciones lineales simples entre el tiempo/espacio y el crimen. El modelo avanzado (KNN) se comparará contra esta línea base para demostrar empíricamente que la utilización de Inteligencia Artificial para el descubrimiento de patrones no lineales realmente aporta valor operativo a las instituciones del Estado.

## 19-Diseño de experimentación

Para asegurar la validez interna del estudio, se diseñó un entorno de experimentación controlado que aísla el rendimiento de los clasificadores:

**Tabla 4:** Diseño de Experimentos controlados

| Experimento | Modelo                         | Variables                 | Parámetros              | Métrica          |
|-------------|--------------------------------|---------------------------|-------------------------|------------------|
| E1          | Regresión Logística (Baseline) | Espaciotemporales (V1-V6) | class_weight='balanced' | F1-Score (Macro) |
| E2          | K-Nearest Neighbors (KNN)      | Espaciotemporales (V1-V6) | Tuned: n_neighbors=1    | F1-Score (Macro) |
| E3          | Random Forest (Avanzado 2)     | Espaciotemporales (V1-V6) | class_weight='balanced' | F1-Score (Macro) |

### Explicación del diseño experimental:

- **Qué cambia:** Únicamente la arquitectura del algoritmo de clasificación (modelo lineal en E1 frente a un modelo no paramétrico de vecindad en E2).
- **Qué permanece constante:** El subconjunto de datos de prueba, la semilla de aleatoriedad (random\_state=42), las variables de entrada, la variable objetivo y la estandarización previa de los tensores.
- **Qué se mide:** La métrica F1-Score (Macro), elegida por su robustez frente al severo desbalance de clases de los datos del MININTER.
- **Por qué se realiza el experimento:** Para demostrar científicamente si el reconocimiento de patrones de vecindad histórica (KNN) supera a las regresiones estadísticas probabilísticas simples, validando así la hipótesis tecnológica del proyecto.

## 20-Evaluación

### 20.1. Métricas de Evaluación

Dada la naturaleza del fenómeno criminal peruano, el dataset presenta un desbalance de clases bastante marcado [15] [16]. Por esa razón, la elección de la métrica no fue arbitraria: se descartó la exactitud (Accuracy), ya que en este contexto suele dar una imagen engañosa al inclinarse hacia la clase mayoritaria. En su lugar, se optó por el F1-Score (Macro) [17] [18], pues calcula la media armónica entre Precision y Recall promediando todas las clases por igual. Esto asegura que el modelo se evalúe con el mismo rigor tanto para delitos minoritarios (como los secuestros) como para las faltas más comunes.

### 20.2. Validación

Para la validación se dividieron los datos en 80% para entrenamiento y 20% para pruebas (Train/Test Split). Con el fin de evitar que el desbalance afectara los resultados, esta partición se hizo con estratificación, de modo que la proporción de cada tipo de delito se mantuviera igual en ambos conjuntos. No se utilizó una división temporal, ya que el modelo busca identificar relaciones espaciales atemporales y no está pensado para pronosticar series de tiempo.

### 20.3. Comparación de Modelos


**Tabla 5:** Desempeño predictivo de los Algoritmos

| Modelo | Arquitectura                   | F1-Score (Macro) |
|--------|--------------------------------|------------------|
| 0      | Regresión Logística (Baseline) | 0.1306           |
| 1      | K-Nearest Neighbors (K=1)      | 0.0244           |
| 2      | Random Forest (Tuned, n=50)    | 0.037053         |

El modelo Baseline lineal terminó superando a las arquitecturas más avanzadas. Esta ventaja no se explica por su complejidad computacional, de hecho, es el modelo más simple del conjunto, sino por su parámetro de penalización ponderada (`class_weight='balanced'`), que obligó matemáticamente al modelo a prestar atención a las clases minoritarias. En cambio, algoritmos como KNN, al depender de distancias sobre un espacio geográfico codificado, terminaron calculando distancias poco representativas de la realidad, lo que perjudicó su desempeño frente a las clases menos frecuentes.

### 20.4. Interpretabilidad

Para responder por qué el modelo toma determinadas decisiones en un contexto de seguridad pública, se analizó la importancia de las variables (Feature Importance) [23], [24], [25].



**Figura 4:** Gráfico de Importancia de Variables

### 20.5. Evaluación del Artefacto

Desde la perspectiva metodológica de Design Science Research, el sistema desarrollado trasciende la validación puramente matemática (métricas) para evaluarse como un artefacto tecnológico que demuestra utilidad, calidad y eficacia en el contexto de la seguridad ciudadana.

- **Utilidad y Usabilidad:** El sistema resuelve el problema práctico de la sobrecarga de datos, transformando registros masivos incomprensibles manualmente en predicciones estructuradas. Esto otorga a los analistas del MININTER una herramienta directamente utilizable para la planificación táctica de patrullajes.
- **Rendimiento y Tiempo de respuesta:** El pipeline de preprocesamiento e inferencia algorítmica, ejecutado mediante arreglos vectorizados, procesa nuevos vectores de entrada en el orden de los milisegundos, permitiendo clasificaciones de incidencias en tiempo casi real.
- **Robustez y Escalabilidad:** Al apoyarse en la librería `scikit-learn`, la arquitectura es computacionalmente robusta y escalable. El sistema es capaz de ingerir nuevos lotes masivos de denuncias (actualizaciones mensuales del SIDPOL) sin requerir modificaciones estructurales en el código base.
- **Interpretabilidad y Seguridad:** Como se evidenció en la evaluación previa, las decisiones del modelo son completamente auditables, cumpliendo con los estándares de transparencia exigidos para los sistemas tecnológicos integrados a procesos del sector público.

## 20.6. Prototipo

Para demostrar que el modelo algorítmico puede integrarse dentro de una solución de software utilizable por analistas de seguridad, el proyecto contempla la implementación de un prototipo funcional basado en la librería Gradio de Python. Este prototipo, ejecutable directamente desde el entorno virtualizado del notebook, despliega una interfaz gráfica de usuario (GUI) básica. En ella, el operador policial puede ingresar interactivamente los parámetros espaciotemporales (Año, Mes, Departamento y UBIGEO) mediante menús desplegables. En tiempo real, el sistema procesa estas entradas, aplica las transformaciones del pipeline (estandarización y codificación guardadas en memoria) y ejecuta la función de inferencia del modelo base, devolviendo en pantalla la tipología de delito con mayor probabilidad de ocurrencia. (Para visualizar la interfaz gráfica del sistema desarrollado, referirse al Anexo H).


## 20.7. Despliegue

Para poner en marcha el modelo desarrollado, el despliegue se documenta indicando que el entorno de ejecución se basa en servicios cloud, específicamente en Google Colab, mediante notebooks reproducibles. Este enfoque facilita la instalación y ejecución del sistema, ya que todo el código corre de forma secuencial en la nube sin necesidad de compilaciones locales complejas. En cuanto a dependencias, el proyecto se apoya en el ecosistema de Python 3, mientras que el almacenamiento del dataset se gestiona mediante integración con Google Drive, donde también queda alojado el modelo durante la fase de inferencia. Si bien esta etapa experimental no requiere una API orientada a microservicios, el propio entorno interactivo del notebook cumple la función de interfaz principal de evaluación, apoyado en GitHub para el alojamiento y control de versiones del proyecto.

## 21-Resultados

Los resultados obtenidos en la fase de prueba (presentados aquí de forma estrictamente objetiva, sin entrar todavía en su interpretación) muestran el rendimiento real de los clasificadores evaluados. El Modelo Base (Regresión Logística) fue el que obtuvo el mejor desempeño, alcanzando un F1-Score Macro de 0.1306, por encima del Random Forest (0.0370) y del algoritmo KNN (0.0244).

Para detallar la distribución de aciertos y falsos positivos del modelo de mejor rendimiento (Baseline), se generó la respectiva matriz de confusión multiclase:



**Figura 5:** Gráfico de la Matriz de Confusión

## 22-Discusión

Al analizar los resultados de la fase experimental, es posible contrastar el desempeño del modelo con los objetivos, hipótesis y expectativas planteadas al inicio de la investigación. La hipótesis original suponía que arquitecturas no paramétricas más complejas, como K-Nearest Neighbors o Random Forest, superarían ampliamente a los métodos estadísticos tradicionales. Sin embargo, los hallazgos apuntaron en la dirección contraria: el sistema funcionó correctamente como artefacto de software, pero en cuanto a rendimiento analítico, fue el Modelo Base (Regresión Logística) el que terminó superando a las arquitecturas más avanzadas.

Este resultado —el buen desempeño relativo del modelo base frente al fallo de los modelos complejos— se explica en gran medida por la naturaleza del preprocesamiento espacial. La Regresión Logística se benefició de su configuración de pesos balanceados (`class_weight='balanced'`), que obligó matemáticamente al algoritmo a prestar atención a los delitos minoritarios más críticos. Los modelos avanzados, en cambio, tropezaron al procesar las variables geográficas (Departamentos, Provincias) que habían sido transformadas mediante LabelEncoding [19] [20]. Algoritmos basados en distancias, como KNN, interpretaron estos códigos nominales como si fueran secuencias ordinales, asumiendo distancias euclidianas que geográficamente no existen, lo que degradó severamente su capacidad de generalización.

En cuanto a la importancia de las variables de entrada, el análisis de Feature Importance mostró que las variables espaciales —en particular el UBIGEO y el Distrito— resultaron muchísimo más relevantes para el modelo que las variables temporales, como el mes o el año. Este hallazgo coincide con lo que plantea la literatura sobre criminología ambiental y la teoría de las actividades rutinarias, cuerpo de investigación que sostiene que la ubicación espacial es uno de los predictores más robustos de la victimización.

Aun así, hay diferencias metodológicas importantes frente a otros trabajos exitosos en la literatura. Mientras que varios estudios logran alta precisión predictiva apoyándose en sistemas de información geográfica (GIS) con coordenadas exactas de latitud y longitud, este proyecto se vio limitado a agrupaciones nominales más amplias provenientes del SIDPOL, lo que redujo la granularidad con la que el algoritmo pudo aprender.

En el contexto real de la seguridad ciudadana y la administración pública, estos resultados dejan una lección importante. Le muestran a instituciones como el MININTER y la Policía Nacional del Perú que no basta con

tabular el historial de ubicaciones y fechas para anticipar con precisión el modus operandi criminal. Para que el Estado peruano avance hacia un modelo real de Predictive Policing, será necesario enriquecer las bases de datos de denuncias con variables exógenas y contextuales —como iluminación urbana, reportes de serenazgo, densidad poblacional y factores socioeconómicos—, de modo que los algoritmos cuenten con el contexto multidimensional necesario para anticipar la criminalidad con eficacia operativa.

## **23-Amenazas de Validez**

Para garantizar el rigor científico de la investigación, se identificaron las siguientes amenazas potenciales y limitaciones del estudio.

Validez interna: ¿el experimento realmente demuestra lo que afirma? El diseño experimental logró aislar el rendimiento de los algoritmos, pero existe el riesgo de variables de confusión no medidas. El modelo asume que el crimen depende únicamente del tiempo y el UBIGEO, dejando fuera variables exógenas que podrían explicar mejor el fenómeno, como la iluminación urbana o la densidad policial.

Validez externa: ¿los resultados pueden generalizarse a otros contextos? Estos resultados son bastante específicos para la demografía y la fenomenología criminal del Perú en el periodo 2018-2026, por lo que no sería correcto extrapolar el desempeño de estos modelos a otros países o jurisdicciones con dinámicas delictivas distintas.

Validez de constructo: ¿las métricas representan realmente lo que se quiere estudiar? Si bien el F1-Score ayudó a mitigar el problema del desbalance de clases, es una métrica puramente matemática que no captura el "costo social" de un error predictivo; por ejemplo, clasificar un secuestro como un hurto simple tiene un impacto mucho mayor que el error inverso.

Validez de conclusión: ¿la evidencia estadística sustenta las conclusiones? La superioridad del modelo base está respaldada matemáticamente por las métricas de evaluación. Sin embargo, las restricciones de tiempo y de cómputo impidieron una optimización exhaustiva de hiperparámetros (un GridSearch más profundo) en el Random Forest, lo que probablemente habría mejorado su rendimiento.

Sesgo y calidad de datos: existe un sesgo inherente en los datos, conocido como la cifra negra de la criminalidad. El dataset solo refleja los delitos que fueron denunciados, no la totalidad de los que realmente ocurrieron, lo que inclina al modelo hacia las zonas donde la población tiende más a denunciar. Aun con esta limitación, el tamaño de la muestra —más de 369,000 registros— le da al entrenamiento una robustez estadística considerable.

## **24-Consideraciones éticas**

Desarrollar sistemas de inteligencia artificial para la seguridad pública exige un análisis ético cuidadoso.

Privacidad, anonimización y consentimiento: el proyecto utilizó datos abiertos gubernamentales. Se verificó que el dataset no contiene identificadores personales (nombres, DNI, direcciones exactas de las víctimas), cumpliendo así con el principio de anonimización y con la Ley de Protección de Datos Personales del Perú. Al tratarse de datos públicos agregados, el consentimiento queda gestionado a nivel estatal. Sesgo algorítmico y discriminación: existe el riesgo real de generar "bucles de retroalimentación" discriminatorios [27] [28]. Si el modelo predice más delitos en ciertos distritos vulnerables, esto puede traducirse en mayor presencia policial en esas zonas, lo que a su vez genera más arrestos y denuncias, "confirmando" el sesgo del modelo y estigmatizando aún más a esas poblaciones [26] [29] [30].

Uso responsable y explicabilidad: esta solución predictiva debe entenderse estrictamente como una herramienta de apoyo analítico, no como un sistema de decisión autónomo. Por eso la explicabilidad del modelo —lograda aquí mediante el Feature Importance— es tan importante: permite que las autoridades policiales entiendan que la máquina sugiere patrones espaciales, pero que la decisión final de despliegue debe seguir siendo humana.

Propiedad intelectual y seguridad: los datos pertenecen al Estado peruano, y el modelo desarrollado respeta las licencias de Open Data.

## **25- Reproducibilidad**

La reproducibilidad es un aspecto clave en la investigación empírica de ingeniería de software y en los experimentos basados en datos. Para que cualquier otro estudiante pueda reconstruir este experimento con exactitud, se entrega el código fuente alojado en el repositorio, junto con su documentación e instrucciones de ejecución. Asimismo, se proporciona el mecanismo de acceso al dataset oficial, respetando los parámetros legales correspondientes, mientras que la descripción del entorno virtualizado y las versiones de las librerías utilizadas cumplen la función de un archivo requirements.txt. Por último, la configuración del modelo y la validación de resultados quedan aseguradas matemáticamente gracias a que se fijaron de forma estricta las semillas aleatorias (random\_state=42) en todas las funciones estocásticas, lo que garantiza que todo el diseño experimental sea completamente auditable.

## 26-Conclusiones

Las conclusiones derivadas del análisis experimental responden directamente a los objetivos planteados.

En cuanto al OE1, el Análisis Exploratorio de Datos permitió identificar que el fenómeno delictivo nacional presenta un desbalance de clases severo y una alta concentración en distritos urbanos específicos, lo que confirma la fuerte dependencia espacial del crimen. Respecto al OE2, el proceso de preparación e ingeniería de datos permitió estructurar un pipeline de LabelEncoding y estandarización sin fugas de información (data leakage), lo que garantizó un entorno de aprendizaje matemáticamente válido. En cuanto al OE3 y al OE4, se logró diseñar y entrenar de forma funcional tanto un modelo base (Regresión Logística) como arquitecturas más avanzadas (KNN, Random Forest), evaluándolas con métricas robustas como el F1-Score para mitigar el sesgo hacia las clases mayoritarias.

Finalmente, respecto al OE5, la comparación arrojó un resultado sorprendente: el modelo lineal base superó a las inteligencias artificiales no paramétricas (F1-Score de 0.13 frente a 0.03). Esto sugiere que codificar zonas geográficas amplias mediante valores nominales termina perjudicando a los algoritmos basados en vecindad, haciendo que los enfoques lineales ponderados resulten, en este caso, más efectivos.

## 27-Recomendaciones

A partir de las limitaciones identificadas en el proyecto, se plantean las siguientes recomendaciones:

Se recomienda a las entidades del sector público dejar atrás la codificación nominal de ubicaciones y empezar a capturar coordenadas geográficas exactas (latitud y longitud) en el SIDPOL, de modo que se puedan potenciar los modelos predictivos.

También se sugiere implementar métricas de evaluación que penalicen de forma asimétrica los falsos negativos en delitos de alto impacto social, en lugar de tratar a todas las categorías con el mismo peso.

### 27.1. Trabajo Futuro

Para extender los alcances de esta investigación, se proponen las siguientes líneas de trabajo futuro:

-Nuevos datos y dominios: integrar variables exógenas al modelo, como los censos socioeconómicos del INEI y las bases de datos del Servicio Nacional de Meteorología e Hidrología (SENAMHI), para evaluar qué tanto influye el clima en la criminalidad.

-Nuevos algoritmos y aprendizaje continuo: explorar redes neuronales espaciotemporales (Graph Neural Networks) y modelos de Gradient Boosting (XGBoost, LightGBM) dentro de un esquema de aprendizaje continuo que se retroalimente con los reportes diarios de las comisarías.

-Despliegue productivo: empaquetar el modelo en contenedores Docker y exponerlo mediante una API construida con FastAPI, para integrarlo con los sistemas operativos de Serenazgo y la Policía Nacional.

## 28-Referencias

[1] Schröer, C., Kruse, F., & Gómez, J. M. (2021). A Systematic Literature Review on Applying CRISP-DM Process Model. *Procedia Computer Science*, 181, 526-534. Recuperado de <https://doi.org/10.1016/j.procs.2021.01.199>

- [2] Buitinck, L., et al. (2013). API design for machine learning software: experiences from the scikit-learn project. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1309.0238>
- [3] McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference, 51-56. Recuperado de <https://conference.scipy.org/proceedings/scipy2010/pdfs/mckinney.pdf>
- [4] Kluyver, T., et al. (2016). Jupyter Notebooks - a publishing format for reproducible computational workflows. Positioning and Power in Academic Publishing: Players, Agents and Agendas, 87-90. Recuperado de <https://eprints.soton.ac.uk/403913/1/jupyter.pdf>
- [5] Kounadi, O., Ristea, A., Leitner, M., & Langford, C. (2020). A systematic review on spatial crime forecasting. Crime Science, 9(1), 1-22. Recuperado de <https://crimesciencejournal.springeropen.com/articles/10.1186/s40163-020-00115-4>
- [6] Bogomolov, A., Lepri, B., Staiano, J., Oliver, N., Pianesi, F., & Pentland, A. (2014). Once Upon a Crime: Towards Crime Prediction from Demographics and Mobile Data. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1409.0666>
- [7] Alves, L. G., Ribeiro, H. V., & Mendes, R. S. (2018). Crime prediction through urban metrics and statistical learning. PLOS ONE, 13(4), e0194364. Recuperado de <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0194364>
- [8] Rummens, W., Hardyns, W., & Pauwels, L. (2017). The use of predictive analysis in spatiotemporal crime forecasting. Journal of Big Data, 4(1), 1-15. Recuperado de <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-017-0081-3>
- [9] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830. Recuperado de <https://jmlr.csail.mit.edu/papers/v12/pedregosa11a.html>
- [10] Biau, G., & Scornet, E. (2016). A random forest guided tour. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1511.02458>
- [11] Probst, P., Wright, M. N., & Boulesteix, A. L. (2019). Hyperparameters and tuning strategies for random forest. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1804.03515>
- [12] Schliep, K. P., & Hechenbichler, K. (2016). kkn: Weighted k-Nearest Neighbors. The Comprehensive R Archive Network. Recuperado de <https://arxiv.org/abs/1708.04321>
- [13] Kleinbaum, D. G., & Klein, M. (2010). Logistic Regression. ArXiv / Open Statistics. Recuperado de <https://arxiv.org/abs/1510.02840>
- [14] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321-357. Recuperado de <https://www.jair.org/index.php/jair/article/view/10302>
- [15] Branco, P., Torgo, L., & Ribeiro, R. P. (2016). A Survey of Predictive Modeling on Imbalanced Domains. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1505.01658>
- [16] He, H., & Garcia, E. A. (2009). Learning from Imbalanced Data. IEEE Transactions on Knowledge and Data Engineering. Recuperado de [https://www.researchgate.net/publication/224167199\\_Learning\\_from\\_Imbalanced\\_Data](https://www.researchgate.net/publication/224167199_Learning_from_Imbalanced_Data)
- [17] Lipton, Z. C., Elkan, C., & Naryanaswamy, B. (2014). Optimal Thresholding of Classifiers to Maximize F1 Measure. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1402.1892>
- [18] Reinke, A., et al. (2021). Metrics reloaded: Pitfalls and recommendations for image analysis validation. ArXiv Preprint. (Aplica para selección de métricas). Recuperado de <https://arxiv.org/abs/2206.01653>

- [19] Cerda, P., Varoquaux, G., & Kégl, B. (2018). Similarity encoding for learning with dirty categorical variables. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1806.00939>
- [20] Micci-Barreca, D. (2001). A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems. SIGKDD Explorations. Recuperado de <https://dl.acm.org/doi/pdf/10.1145/507533.507538>
- [21] Kaufman, S., Rosset, S., & Perlich, C. (2012). Leakage in Data Mining: Formulation, Detection, and Avoidance. Proceedings of KDD. Recuperado de [https://www.researchgate.net/publication/262272361\\_Leakage\\_in\\_Data\\_Mining](https://www.researchgate.net/publication/262272361_Leakage_in_Data_Mining)
- [22] Kapoor, S., & Narayanan, A. (2022). Leakage and the Reproducibility Crisis in ML-based Science. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/2207.03061>
- [23] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1602.04938>
- [24] Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1705.07874>
- [25] Doshi-Velez, F., & Kim, B. (2017). Towards A Rigorous Science of Interpretable Machine Learning. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1702.08608>
- [26] Richardson, R., Schultz, J., & Crawford, K. (2019). Dirty Data, Bad Predictions: How Civil Rights Violations Impact Police Data, Predictive Policing Systems, and Justice. SSRN. Recuperado de [https://papers.ssrn.com/sol3/papers.cfm?abstract\\_id=3247554](https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3247554)
- [27] Ensign, D., Friedler, S. A., Neville, S., Scheidegger, C., & Venkatasubramanian, S. (2018). Runaway Feedback Loops in Predictive Policing. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1706.09847>
- [28] Lum, K., & Isaac, W. (2016). To predict and serve? SSRN. Recuperado de [https://papers.ssrn.com/sol3/papers.cfm?abstract\\_id=2849887](https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2849887)
- [29] Selbst, A. D., Boyd, D., Friedler, S. A., Judson, S., & Venkatasubramanian, S. (2019). Fairness and Abstraction in Sociotechnical Systems. ACM FAT\*. Recuperado de <https://arxiv.org/abs/1811.11154>
- [30] Jacobs, A. Z., & Wallach, H. (2021). Measurement and Fairness. ArXiv Preprint. Recuperado de <https://arxiv.org/abs/1912.05511>

## 29-Anexos

Se incorporan los siguientes anexos como respaldo técnico de la investigación:

- **Anexo A:** Descripción completa y diccionario de datos del dataset del MININTER.

Dado que el conjunto de datos poblacional (SIDPOL 2018-2026) supera los 369,000 registros, su inclusión física o tabulada en este documento resulta inviable. El archivo .csv original e íntegro se encuentra alojado y disponible para auditoría en la carpeta data/ del repositorio oficial del proyecto.

- **Anexo B:** Enlace al repositorio de GitHub con el código fuente en Python.

Todo el código fuente desarrollado en el entorno de Google Colab, el cual abarca desde el Análisis Exploratorio de Datos (EDA) hasta el despliegue del prototipo, está versionado de forma pública en el siguiente repositorio:

<https://github.com/Santixcross/PROYECTO-IA/tree/main>


- **Anexo C:** Resultados completos de la ejecución en consola (Google Colab).

Los logs completos de entrenamiento algorítmico, las iteraciones de la estandarización y los reportes detallados de métricas multiclase pueden ser reproducidos y verificados ejecutando las celdas del notebook principal ubicado en la carpeta notebooks/ del repositorio.

- **Anexo D:** Configuración de experimentos y parámetros de estandarización.

La configuración determinista que garantiza la reproducibilidad de este estudio (como el uso estricto de `random_state=42` en las particiones estratificadas y la instanciación de hiperparámetros como `class_weight='balanced'`) se encuentra documentada dentro de la Sección 18 del presente informe y en los bloques de inicialización del código fuente.


- **Anexo H:** Capturas del prototipo



**Figura 6:** Capturas del prototipo

## 29.1. Repositorio del Proyecto

La estructura del repositorio alojado en GitHub sigue las convenciones de reproducibilidad para proyectos de Inteligencia Artificial:



**Figura 6:** Captura de estructura del repositorio alojado en GitHub

## 29.2. Readme Obligatorio

El repositorio del proyecto cuenta con un archivo `README.md` estructurado para garantizar que cualquier investigador pueda comprender y reproducir el experimento. A continuación, se documentan las respuestas a las interrogantes fundamentales del sistema:

### 1. ¿Cuál es el problema?

La limitada capacidad analítica de las instituciones de seguridad ciudadana para predecir y clasificar automáticamente las tipologías de delitos basándose en datos históricos masivos.

## 2. ¿Cuál es el objetivo?

Desarrollar, evaluar y comparar modelos de Machine Learning (Regresión Logística, KNN, Random Forest) para clasificar tipos de delitos utilizando exclusivamente coordenadas espaciotemporales estructuradas.

## 3. ¿Qué dataset se utilizó?

Los datos abiertos oficiales del Sistema de Denuncias Policiales (SIDPOL) del Ministerio del Interior del Perú, abarcando 369,100 registros desde el año 2018 hasta julio de 2026.

## 4. ¿Cómo obtener los datos?

El archivo original puede ser descargado desde la Plataforma Nacional de Datos Abiertos del Estado Peruano (Sección Observatorio Nacional de Seguridad Ciudadana) o contactando directamente a la fuente gubernamental.

## 5. ¿Cómo instalar el proyecto?

No se requiere instalación local ni configuración de infraestructura compleja. Basta con clonar el repositorio y cargar el entorno interactivo (Jupyter Notebook / Google Colab). Las dependencias requeridas son nativas del ecosistema de ciencia de datos (pandas, scikit-learn, matplotlib, seaborn).

## 6. ¿Cómo ejecutar el código?

Se debe abrir el notebook principal, montar el directorio donde se ubica el archivo .csv (mediante Google Drive o entorno local) y ejecutar las celdas de preparación de manera secuencial.

## 7. ¿Cómo entrenar el modelo?

Ejecutando la celda de la sección de Modelado. El código instancia automáticamente el preprocesamiento (LabelEncoder, StandardScaler) y entrena los modelos matemáticos con los parámetros ya optimizados.

## 8. ¿Cómo reproducir los experimentos?

El experimento es 100% determinista. El código mantiene un entorno controlado al fijar la semilla aleatoria (random\_state=42) en la partición estratificada de datos y en los hiperparámetros de los algoritmos.

## 9. ¿Cómo ejecutar el prototipo?

La evaluación del modelo se visualiza interactivamente a través de la consola del notebook, la cual imprime las métricas de rendimiento y genera visualmente las matrices de confusión tras la fase de predicción (Predict).

## 10. ¿Cuáles fueron los resultados?

Contrario a la hipótesis inicial, el Modelo Base (Regresión Logística multinomial con pesos balanceados) obtuvo el mayor rendimiento predictivo global (F1-Score Macro: 0.1306), superando a las arquitecturas avanzadas de Random Forest (0.0370) y KNN (0.0244). Esto demostró empíricamente que la conversión nominal de variables geográficas severamente desbalanceadas degrada el rendimiento de los algoritmos basados en distancias euclidianas.

### 29.3. Matriz de Trazabilidad final

Al finalizar el proyecto, se evidencia la trazabilidad y coherencia metodológica entre los objetivos planteados al inicio y los resultados tangibles entregados:

| Objetivo | Actividad                                      | Artefacto                | Evidencia                               | Resultado                                             | Sección del paper                 |
|----------|------------------------------------------------|--------------------------|-----------------------------------------|-------------------------------------------------------|-----------------------------------|
| OE1      | Análisis de la criminalidad y desbalance       | Modelo del problema      | Estadísticas del MININTER               | Problema caracterizado                                | Introducción                      |
| OE2      | Análisis exploratorio (EDA) y preprocesamiento | Dataset limpio (SIDPOL)  | Gráficos de barras y auditoría de nulos | Variables predictoras espaciales identificadas        | Metodología                       |
| OE3      | Desarrollo algorítmico (Baseline, KNN, RF)     | Pipeline de Modelos IA   | Código fuente en Python                 | Modelos matemáticos entrenados                        | Desarrollo e Implementación       |
| OE4      | Diseño de experimentos controlados             | Protocolo de evaluación  | Métricas robustas (F1-Score Macro)      | Rendimiento predictivo cuantificado                   | Resultados                        |
| OE5      | Comparación de rendimiento algorítmico         | Matriz de evaluación     | Tablas y Matriz de Confusión            | Regresión Logística seleccionada como modelo superior | Discusión                         |
| OE6      | Despliegue de prototipo analítico              | Repositorio estructurado | Cuaderno de Colab ejecutable en GitHub  | Artefacto funcional y reproducible validado           | Implementación y Reproducibilidad |